

智能问答系统

版本

v1.1

文档日期

2026-09-15

读者对象

系统管理员 / 业务分析师 / AI 应用开发者

目录

第 1 章 系统概述.....	4
1.1 系统定位	4
1.2 四大核心能力	4
1.3 系统分层架构	4
第 2 章 核心概念与术语	5
2.1 本体	5
2.2 数据源	6
第 3 章 系统初始化顺序	6
第 4 章 审计安全	6
第 5 章 数据源配置	7
第 6 章 本体管理	7
6.1 本体是什么	7
6.2 通过 UI 管理本体	7
6.3 通过 CHAT 创建本体（知识指令）	8
6.4 三库一致性	8
6.5 本体属性管理	8
第 7 章 模型路由配置.....	8
7.1 模型配置页面	8
7.2 EMBEDDING PROVIDER 配置	9
第 8 章 智能问答	9
第 9 章 智能分析	11
9.1 数据质量	11
9.2 数据血缘	11
9.3 编码映射	11
9.4 KPI CATALOG	11
9.5 数据质量规则自动生成	12
第 10 章 AI AGENT 平台.....	12

10.1 AGENT 的概念.....	12
10.2 管理 AGENT	12
10.3 通过 CHAT 调用 AGENT.....	12
第 11 章 企业级 WIKI 与知识管理.....	13
11.1 章节导览.....	13
11.2 维知识结构.....	13
11.3 管理页面	14
11.3.1 Wiki 页面	14
11.3.2 Wiki 导入	14
11.3.3 Wiki 图谱	15
11.4 知识问答.....	15
11.5 知识成长	16
11.6 与本体（ONTOLOGY）的关系	16

第 1 章 系统概述

1.1 系统定位

智能问答系统（QA System）是一款面向企业数据场景的 NL2SQL + AI 分析平台。用户通过自然语言提问，系统自动完成「意图识别 → 本体匹配 → 模型路由 → SQL 生成 → 只读查询 → 图表渲染 → 智能回答」的完整链路，并在多个业务域内置了数据治理、AI 特征、Agent 平台等模块。

本系统不是简单的「聊天机器人」，而是把企业的「数据 + 本体 + 模型 + 业务对象 + 智能 Agent」整合成一个可治理、可计量、可审计的统一入口。

1.2 四大核心能力

能力	说明	对应模块
自然语言查询	自然语言 → SQL → 业务库只读查询 → 图表	ChatService
多模型路由	加权随机 + 成本阈值熔断 + 会话亲和 + 预算降级	ModelRouterService
本体治理	类/属性/指标定义 → PG + Neo4j + Milvus 三向同步	本体服务
知识库	知识库管理，导入企业文本知识，可以独立当作知识库，还可以与本体关联	企业 Wiki

1.3 系统分层架构

系统采用分层架构，自顶向下分为用户接入层、API 层、领域服务层、基础设施层与持久化层。每一层只依赖下层，不跨层调用。

层级	组件	功能
接入层	React + Vite + ECharts	对话 UI、表单、图表渲染
API 层	FastAPI Router	RESTful 端点、限流、鉴权
领域服务层	Chat / NL2SQL / Ontology / Agent 等 Service	业务编排与策略
基础设施层	BusinessDbAdapter / LlmFactory / TokenCounter	SQL 护栏、LLM 抽象、Token 计量
持久化层	PostgreSQL / Neo4j / Milvus / MySQL (业务库)	元数据、知识落盘，目标数据库可选 Oracle、PG、MySQL、SqlServer 等， 有权限访问即可。

第 2 章 核心概念与术语

2.1 本体

本体是连接业务语言与数据库的「语义层」。一个类 (Class) 对应业务上的一个实体 (如「供应商」)，一个属性 (Property) 对应一个字段 (如「供应商名称」)，一个指标 (Metric) 对应一个聚合表达式 (如「近 3 个月 OTD」)。

PG 持久化到 PostgreSQL：结构化存储

Neo4j 持久化到 Neo4j：本体图 + 语义关系

Milvus 持久化到 Milvus：类名 / 属性名 / 业务描述的向量，用于语义检索

2.2 数据源

数据源是用户查询的目标业务库连接。目前系统支持 MySQL、PostgreSQL、Oracle、SQL Server、以及任何 SQLAlchemy 支持的方言。配置完成后会做：

探测连接可用性。

Schema 缓存 (introspect)：从 information_schema / 数据字典读取表/列元数据，用于本体漂移检测。

第 3 章 系统初始化顺序

在「系统配置 → 模型配置」录入至少一个 LLM 模型（OpenAI/DeepSeek/Qwen/Ollama 任一）。

在「业务基础信息 → 数据源」注册业务库（至少包含 Demo MySQL wms_demo）。

在「业务配置 → 本体」查看已创建的类与属性。

在「业务基础信息 → 数据源」对目标库做 introspect，把表/列元数据缓存。

在「AI Agent → 智能问答」/chat 用自然语言提问，观察 SQL 渲染、图表、Token 用量。

在「系统信息配置 → 服务状态」确认 PG / Neo4j / Milvus 健康。

在「业务配置 → 数据质量」录入规则并评估。

第 4 章 审计安全

查看系统对于系统配置和业务配置的变更记录。

第 5 章 数据源配置

数据源是 Chat 查询的目标——所有 NL2SQL 生成的 SQL 都会路由到这里执行。系统通过 BusinessDbAdapter 屏蔽方言差异，SQL Guard 强制只读。

第 6 章 本体管理

6.1 本体是什么

本体是连接业务语言与数据库的「语义层」。它由三类对象组成：

类 Class 代表业务实体（如 Supplier 供应商、PurchaseOrder 采购订单）

属性 Property 类的字段（如 supplier_name、order_amount）

指标 Metric 可计算的指标（如 OTD_3M = SUM(on_time_delivery_qty)/SUM(ordered_qty)，3 个月窗口）

6.2 通过 UI 管理本体

菜单入口：「业务配置 → 本体」。页面支持 4 个 Tab：

Tab	操作
类 (Classes)	新增/编辑/启停；定义类名、显示名、所属业务域、源表
属性 (Properties)	绑定到类，关联数据源列
指标 (Metrics)	定义聚合表达式 (SQL 片段 / Python 计算)
Join 关系	定义类之间的 JOIN 路径 (JoinableWith / ForeignKey)

6.3 通过 Chat 创建本体（知识指令）

Chat 支持「DEFINE / MAP / METRIC」三类知识指令，例如：

- 「定义一个类：供应商，源表是 supplier」
- 「给 supplier 映射属性 supplier_name，指向 wms_demo.supplier.name」
- 「定义指标 OTD_3M，公式 $SUM(on_time_qty)/SUM(ordered_qty)$ 」

系统会写入 ontology_class / ontology_property / ontology_metric 三张表，并同步到 Neo4j 与 Milvus。

6.4 三库一致性

任何一次写入都会触发（PG + Neo4j + Milvus）三向同步。

6.5 本体属性管理

「业务配置 → 本体属性管理」是独立入口，方便批量查看、维护枚举值、修正业务描述。所有变更实时同步到 Neo4j + Milvus。

第 7 章 模型路由配置

7.1 模型配置页面

菜单入口：「系统信息配置 → 模型配置」。

字段说明：

字段	说明
displayName	前端展示名

字段	说明
provider	openai / azure / deepseek / qwen / ollama
modelName	模型 ID（如 gpt-4o、deepseek-chat、qwen-plus、qwen2.5:14b）
apiKey	明文提交，服务端 SECRET_KEY 加密后落库（password_encrypted）
baseUrl	API 端点（兼容代理或 Ollama 地址）
weight	加权随机权重（越大越容易被选中）
costPer1kInput / costPer1kOutput	每千 token 单价（美元），用于成本估算
costThreshold	本模型单次成本上限（美元）
isActive	停用 / 启用（停用后从候选池剔除）

7.2 Embedding Provider 配置

菜单入口：「系统信息配置 → Embedding Providers」。

系统默认使用 Milvus 做语义检索，对 embedding_provider_registry 做集中管理。bge-m3 是 1024 维，必须与 Milvus 集合维度一致。

第 8 章 智能问答

进入「AI Agent → 智能问答」。

顶部选择数据源（dropdown）、模型（dropdown，可选「自动」走 router）。

左侧抽屉可展开「历史会话」面板，导入历史会话或删除。

输入问题按回车发送；流式路径会逐字渲染回答，并显示 SQL、图表、Token 用量。

可对单条问答「导出 PDF」（顶部按钮或每条消息右上角）。

可点击「新建对话」清空当前会话并生成新会话。

对话的效率取决于访问数据的数量级，几十万级别大概几秒钟的时间，百万级约 10 秒以上，目标的底层数据需要根据冷热数据原则同时按照数据仓库的架构进行数据准备，避免大表的查询。

典型问法示例

用户问法	路由	效果
查询 2024 年采购订单数量	NL2SQL 单步	生成 SQL → 表格 + 柱状图
统计供应商数量、计算订单总额	多步（并列复合）	拆成 2 步 → 2 张表 / 图
供应商 100001 的 360° 视图	SUPPLIER_360	Supplier360Card 卡片（编码 / KPI）
供应商 100001 的风险	SUPPLIER_RISK	SupplierRiskCard 卡片（High/Medium/Low + 建议动作）
供应商 100001 和 100002 的关系	GRAPH_RELATIONING	Neo4j 多跳 → 关系图
用 supplier_risk_agent 评估 100001	AGENT_RUN	AgentResponseCard（tool=supplier_risk）
OTD 是什么意思？	CLARIFY	本体概念解释（不调 SQL）
你好	CHITCHAT	问候语（不调 LLM，不记 Token）

用户问法	路由	效果
定义一个类：客户	DEFINE	写入 ontology_class

第 9 章 智能分析

9.1 数据质量

菜单入口：「业务配置 → 数据质量」。5 维评估执行器（COMPLETENESS / VALIDITY / UNIQUENESS / CONSISTENCY / REFERENTIAL），对每条 DataQualityRule 跑出实际通过率。

在「数据源」下拉选择业务库后录入规则。

评估单条。

批量评估。

评估结果会出现在 Chat 回答的 dataQuality 字段。

9.2 数据血缘

菜单入口：「业务配置 → 血缘」。展示字段级血缘（来源 ETL / 表 / 列）。

9.3 编码映射

菜单入口：「业务配置 → 编码映射」。管理跨系统主数据编码（SAP ↔ Oracle ↔ WMS ↔ Sage X3 等）。

9.4 KPI Catalog

菜单入口：「业务配置 → KPI Catalog」。定义 + 治理企业级 KPI。

9.5 数据质量规则自动生成

菜单入口：「业务配置 → DQ 规则生成」。基于 LLM + 抽样值，自动为指定表推荐 5 维规则。

第 10 章 AI Agent 平台

10.1 Agent 的概念

Agent 是注册到「可调用资产」，由 AgentRuntimeService 调度执行。默认绑定 3 个可运行 Agent：

Agent	工具	效果
SUPPLIER_360_AGENT	supplier_360	返回 Supplier360Read
SUPPLIER_RISK_AGENT	supplier_risk	返回 SupplierRiskRead（含 LLM 风险点）
GRAPH_REASONING_AGENT	graph_traverse	Neo4j 多跳遍历

10.2 管理 Agent

菜单入口：「AI Agent → Agent Registry」+ 「AI Agent → Agent Runtime」。

10.3 通过 Chat 调用 Agent

用户显式指名时（最高优先级意图 AGENT_RUN）：

用 supplier_risk_agent 评估供应商 100001（供应商编码），用 graph_reasoning_agent 查询供应商 100001 和 100002 的关系

第 11 章 企业级 Wiki 与知识管理

11.1 章节导览

本章介绍平台内置的 **企业级 Wiki 系统**——一个通用、可生长的知识管理层。它不锁定任何业务域，可以随知识积累自动扩展，并通过 5 维结构（业务知识 / 管理流程 / 业务定义 / 业务影响 / 业务规则）系统化沉淀企业资产。

一级菜单	路径	主要页面数	用途
企业 Wiki	/wiki/*	7	页面 CRUD、导入、冲突、覆盖、图谱、建议、语义检索
知识问答	/wiki-chat	1	基于 Wiki 的 RAG 问答

11.2 维知识结构

维度（dimension）	含义	典型示例
业务知识 (BUSINESS_KNOWLEDGE)	业务概念 / 流程说明 / 行业知识	「Sage X3 采购订单三向匹配流程」
管理流程 (MANAGEMENT_PROCESS)	审批 / 治理 / 运维流程	「供应商主数据新增审批流程」
业务定义 (BUSINESS_DEFINITION)	字段 / 指标 / 业务规则的权威定义	「OTD 准时率 = SUM(按时交货数量) / SUM(订单数量)」

维度（dimension）	含义	典型示例
业务影响 （BUSINESS_IMPACT）	决策影响 / 风险 / 价值评估	「订单完成率按 YPTHFLGM_0 拆分口径的原因」
业务规则 （BUSINESS_RULE）	可执行规则 （wiki_rule_executable 关联）	「SUPPLIER.YPTHFLGM_0=2 时订单完成率走零库存口径」

11.3 管理页面

11.3.1 Wiki 页面

菜单入口：「企业 Wiki → 页面」。

支持：

- 关键词搜索（标题 / 正文 / 标签）
- 维度过滤
- 批量操作（打标签、改维度、合并）
- 导出（Markdown / PDF / JSON）

11.3.2 Wiki 导入

菜单入口：「企业 Wiki → 导入」。

步骤	操作
1. 上传	PDF / Word / Excel / Markdown / 纯文本
2. 选	选 LLM（继承模型路由）

步骤	操作
模型	
3. 解析	document_parser 提取文本 + 结构
4. 切片	按章节 / 段落 / 滑动窗口切分
5. 分类	LLM 给出 5 维建议 + 标签 + 摘要
6. 去重	与现有 content_hash 比对；撞号则 skipped_pages++
7. 入库	PG wiki_page + wiki_page_embedding (Milvus) + audit
8. 状态	wiki_import_task 表显示进度 + 失败原因

【提示】同一份文件重跑导入 → 第二次显示「skipped_pages=1」且不落副本。

11.3.3 Wiki 图谱

菜单入口：「企业 Wiki → 图谱」。

11.4 知识问答

菜单入口：「AI Agent → 知识问答」（/wiki-chat）。

适用场景：

- 内部规章：「请假流程是怎样的？」（引用 HR 政策页面）
- SOP：「如何新增供应商？」（引用采购 SOP 页面）

- 行业知识：「Sage X3 三向匹配是什么？」（引用业务定义页面）
- 术语词典：「OTD 是什么意思？」（引用术语定义页面）

11.5 知识成长

Wiki 系统会随使用自动成长：

- 使用频率统计：每个 page 的查询次数、被引用次数
- 质量评分：维度完整度、内容长度、引用密度
- AI 推荐补全：基于覆盖度缺口自动推荐需要补的页面
- 业务专家反馈：M3 分类反馈机制，纠正 LLM 错分
- 演化路径：从「业务知识」→「业务定义」→「业务规则」逐步沉

淀

11.6 与本体（Ontology）的关系

维度	Wiki	Ontology
定位	知识文档层	业务结构层（类 / 属性 / 指标）
存储	wiki_page + Milvus	ontology_class/property/metric + Neo4j
检索	语义相似度	精确匹配 + 关系图
治理	LLM 分类 + 专家调整	严格 schema 校验
关系	Neo4j wiki_* 节点（部分）	Neo4j CLASS / HAS_PROPERTY

协同点：

- Wiki 页面可引用 ontology_class（建立知识↔结构桥）
- Chat 命中 ontology 概念时，自动检索相关 Wiki 页面